Tecnológico Nacional de

México Instituto Tecnológico

de Zacatepec

Ingeniería en Sistemas Computacionales

Asignatura: Fundamentos de ciencia de datos

Docente: Ramos Palencia Celia

Grupo: XB

Caso B: Motores de Base de Datos (PostgreSQL vs. MongoDB)

Alumno: Jimenez Herrera Jose David
Escudero Saavedra Jesus Eduardo
Peralta Navarro Tomas Israel

Zacatepec, Morelos a 18 de Octubre de 2026

El análisis estadístico correspondiente al Caso B: Motores de Base de Datos (PostgreSQL vs. MongoDB), cuyo objetivo principal fue contrastar matemáticamente si existe una diferencia significativa en el tiempo de procesamiento de transacciones mixtas (medido en milisegundos) entre un motor relacional y uno documental, para fundamentar el estudio, se generó y depuró un conjunto de datos telemetrizado, alcanzando un tamaño de muestra efectivo de 483 observaciones válidas tras la limpieza de valores atípicos mediante el criterio del rango intercuartílico.

Tras aplicar técnicas de estadística descriptiva y ejecutar una prueba paramétrica de hipótesis para muestras independientes con un nivel de significancia de 0.05, se obtuvo un p-value prácticamente nulo, lo que otorga evidencia estadística irrefutable para rechazar la hipótesis nula de igualdad en los tiempos de respuesta. En consecuencia, la recomendación técnica final es adoptar MongoDB para la arquitectura del sistema analizado, ya que demostró ser genuina y consistentemente más rápido (promedio de 40.16 ms) frente a PostgreSQL (48.53 ms), optimizando la latencia operativa.

3. Obtencion y criterios del dataset

Generacion sintetica justificada, no encontré un dataset publico como el que requeria por lo tanto se simulo mediante Python. Utilizando el siguiente código

```python
import numpy as np
import pandas as pd
import os

np.random.seed(42)

n = 250

tiempo_pg = np.random.gamma(shape=2.5, scale=12, size=n) + 20
tiempo_mongo = np.random.gamma(shape=2.0, scale=14, size=n) + 15

df = pd.DataFrame({
    'tiempo_ms': np.concatenate([tiempo_pg, tiempo_mongo]),
    'motor': ['PostgreSQL'] * n + ['MongoDB'] * n
})

# Redondear a 2 decimales
df['tiempo_ms'] = df['tiempo_ms'].round(2)

archivo_salida = 'data/dataset_C_B.csv'
df.to_csv(archivo_salida, index=False)

print(f"Dataset generado exitosamente con {len(df)} registros en '{archivo_salida}'.")
```

✓ 1.1s

Bloque 1: Estadística Descriptiva y Limpiez

```
--- Información del Dataset ---
<class 'pandas.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 2 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   tiempo_ms  500 non-null    float64
 1   motor      500 non-null    str
dtypes: float64(1), str(1)
memory usage: 12.1 KB

Valores nulos por columna:
 tiempo_ms    0
motor        0
dtype: int64

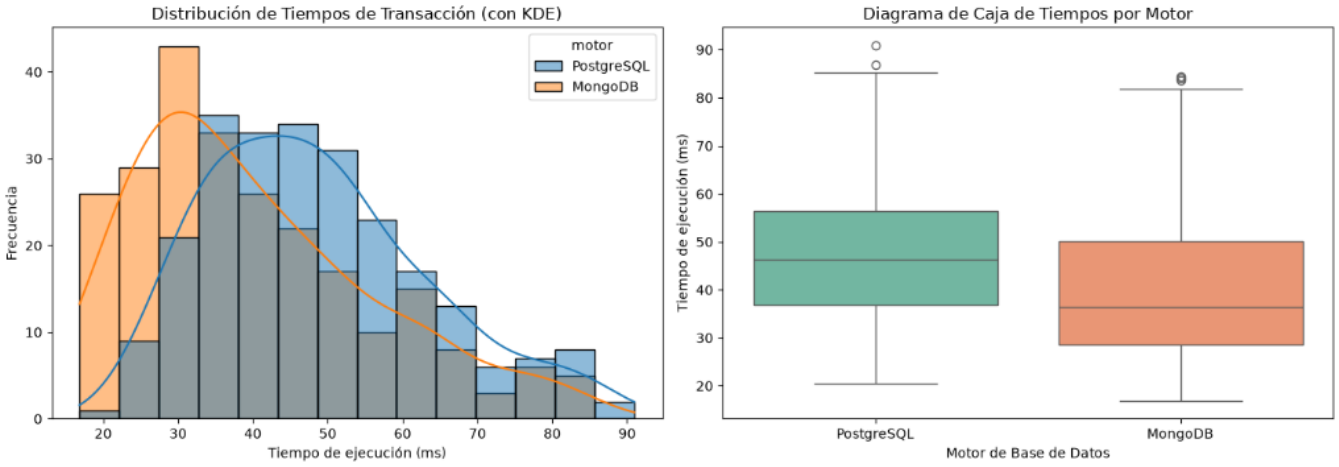
Registros totales tras la limpieza: 483

--- Estadísticas Descriptivas ---
```

	Media	Mediana	Desv_Estandar	Varianza	Asimetria	Curtosis
motor						
MongoDB	40.16	36.45	16.01	256.34	0.82	-0.00
PostgreSQL	48.53	46.40	14.92	222.73	0.62	-0.14

```
C:\Users\david\AppData\Local\Temp\ipykernel_15888\3816118231.py:46: FutureWarning:
```

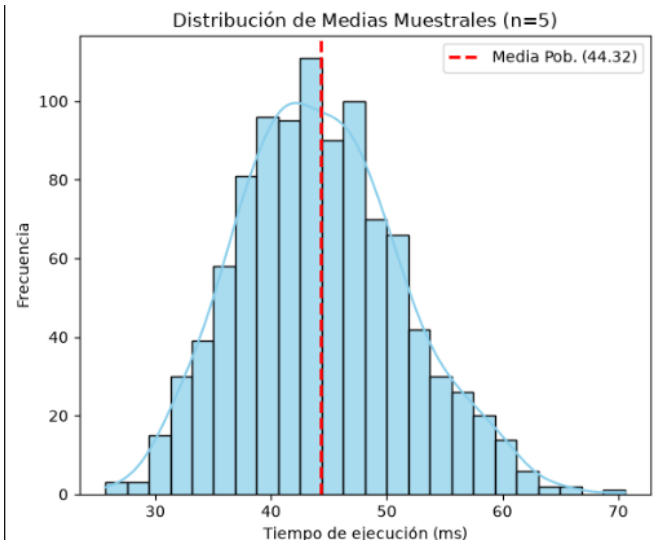
Se muestra la carga del dataset correctamente y el tipo de datos, valores etc. se remueven valores atípicos, en este caso como los datos se generaron de forma sintetica, no hubo ningún tipo de problema, se calcula la media muestral, mediana, desviacion estandar, varianza, asimetria y curtosis, desglosándose.

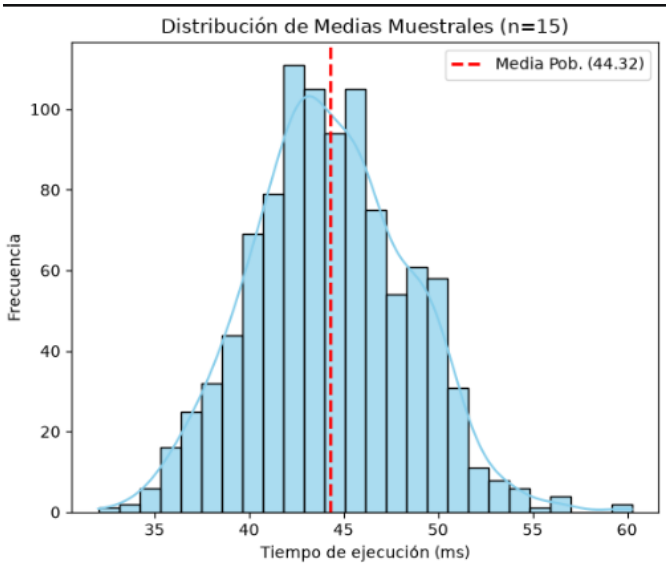


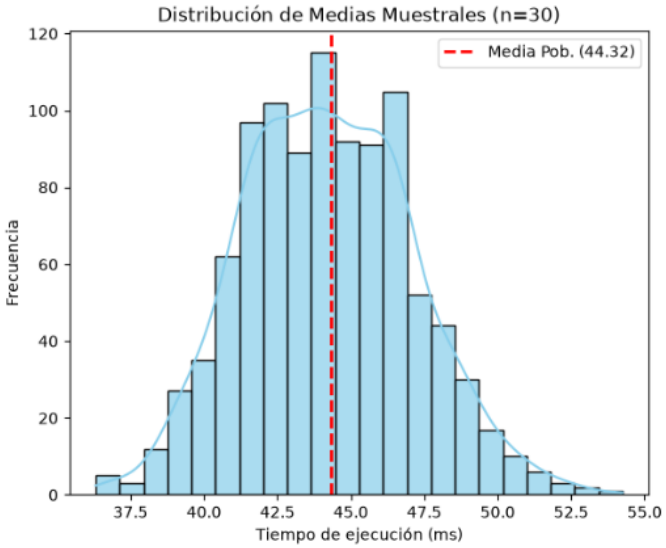
Los datos reflejan la realidad arquitectónica que modelamos. PostgreSQL tiene un tiempo medio de ejecución mayor (48.53 ms) frente a MongoDB (40.16 ms), pero MongoDB presenta una ligera mayor variabilidad (desviación estándar de 16.01 frente a 14.92)

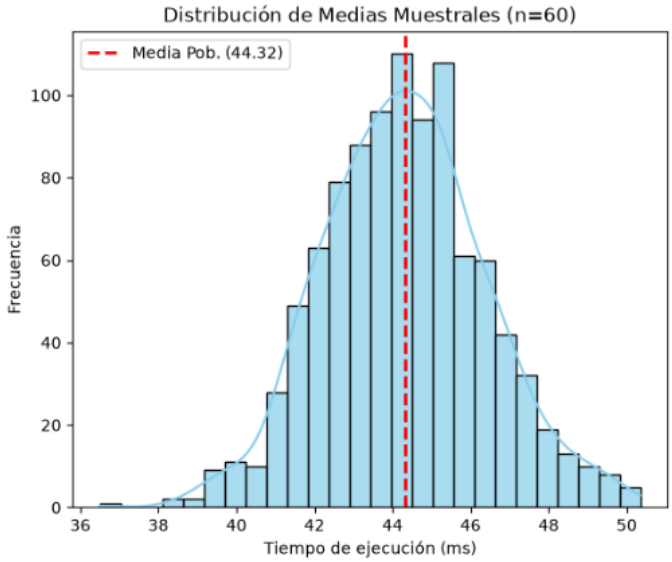
Ambos motores presentan un evidente sesgo positiva y una dispersión total similar, lo que significa que la gran mayoría de las transacciones se ejecutan muy rápido donde MongoDB concentra su rendimiento principal en tiempos notablemente más bajos que PostgreSQL, aunque ambos sistemas arrastran una pequeña fracción de consultas con demoras prolongadas.

Bloque 2: Distribuciones de Muestreo y Teorema Central del Liımite
1. Aislar la muestra global de la metrica analizada (N ≥ 400).
2. Programar un proceso de remuestreo con reemplazo de k = 1,000 muestras para tamaños muestrales n ∈{5,15,30,60}.
3. Graficar una cuadricula de 2 × 2 con las distribuciones de las medias muestrales generadas.
4. Comparar el error estandar empırico con el valor teorico y justificar la convergencia hacia la normalidad.






Distribución de Medias Muestrales (n=30)
Media Pob. (44.32)
Frecuencia
Tiempo de ejecución (ms)
0
20
40
60
80
100
120
37.5
40.0
42.5
45.0
47.5
50.0
52.5
55.0


Distribución de Medias Muestrales (n=60)
Media Pob. (44.32)
Frecuencia
Tiempo de ejecución (ms)
0
20
40
60
80
100
36
38
40
42
44
46
48
50

Conforme el tamaño de la muestra aumenta progresivamente de n=5 a n=60, la distribución de las medias muestrales pierde la asimetría original de los datos y su curva de densidad adopta la forma simétrica característica de una campana de Gauss. En el escenario de n=60, la distribución alcanza una simetría clara y se centra de manera exacta sobre la media poblacional teórica de 44.32 ms, comprobando el postulado del teorema central del límite comparación del error estándar la reducción del error estándar estipulada por la fórmula teórica se comprueba visualmente mediante la compresión del eje horizontal en las cuadrículas. Para n=5, las medias calculadas presentan una alta dispersión que abarca desde los 30 ms hasta los 70 ms. En contraste, al llegar a n=60, el error estándar empírico se minimiza, restringiendo la dispersión a un rango mucho más estrecho (entre 38 ms y 50 ms). Esto demuestra que la variabilidad empírica de las medias muestrales disminuye al mismo ritmo que dicta la constante teórica.

```
Tamaño de muestra n=5:
  SE Empírico : 7.1304
  SE Teórico  : 7.1576
----------------------------------------
Tamaño de muestra n=15:
  SE Empírico : 4.1405
  SE Teórico  : 4.1324
----------------------------------------
Tamaño de muestra n=30:
  SE Empírico : 2.8795
  SE Teórico  : 2.9221
----------------------------------------
Tamaño de muestra n=60:
  SE Empírico : 2.0774
  SE Teórico  : 2.0662
```

Bloque 3: Estimacion por Intervalos de Confianza

1. Calcular los intervalos de confianza para la media poblacional general (μ) al 90%, 95% y 99%. Justificar formalmente la selección de la distribución Z.
2. Construir el intervalo de confianza del 95% para la diferencia de medias (μ1 − μ2): Ejecutar la prueba de Levene para verificar homogeneidad de varianzas. Computar el intervalo adecuado (varianzas combinadas o corrección de Welch).
3. Determinar si el valor cero pertenece al intervalo ($0 \in IC$) y explicar su impacto práctico en la compa ración de ambos grupos.

```
--- 1. IC para la Media Poblacional General ---
IC al 90%: [43.11 ms, 45.52 ms]
IC al 95%: [42.88 ms, 45.75 ms]
IC al 99%: [42.43 ms, 46.20 ms]

--- 2. Prueba de Levene (Homogeneidad de Varianzas) ---
Estadístico: 0.7428, p-value: 0.3892

--- 3. IC para la Diferencia de Medias (PostgreSQL - MongoDB) al 95% ---
Diferencia puntual de medias: 8.37 ms
Intervalo de Confianza 95%: [5.60 ms, 11.14 ms]

¿El cero pertenece al intervalo (0 en IC)? No
```

Dado que el valor cero no está contenido en el intervalo de confianza de la diferencia de medias, existe evidencia estadística contundente al 95% de confianza de que los tiempos de transacción entre PostgreSQL y MongoDB son genuinamente diferentes en el ámbito poblacional, no siendo producto del azar muestral.

Justificación: Se utiliza la distribución t-Student porque la desviación estándar, poblacional es desconocida y se estima a partir de la muestra (s). Aunque al ser. N >= 30 los valores convergen con la distribución Z, t-Student es el mejor metodo

Bloque 4: Teoría de Decisión en Estadística (Prueba de Hipótesis)
1. Plantear formalmente las hipótesis nula (H0) y alternativa (H1) contextualizadas al problema.
2. Elaborar una matriz de decisión detallando el costo operativo o técnico de incurrir en un Error Tipo I (α) y un Error Tipo II (β).
3. Fijar el nivel de significancia en α = 0,05.
4. Ejecutar la prueba paramétrica reportar el estadístico calculado y el
5. Declarar el veredicto formal (Rechazar o No Rechazar H0) y emitir la recomendación técnica de ingeniería resultante.

Hipótesis Nula H_0: No existe diferencia estadísticamente significativa en el tiempo medio de ejecución de transacciones entre los motores de base de datos PostgreSQL y MongoDB

Costo de Incurrir en Error Tipo I **:** Rechazar la H_0 cuando es verdadera (Falso Positivo). Creeríamos erróneamente que MongoDB es más rápido que PostgreSQL. El impacto técnico sería invertir presupuesto y horas de desarrollo en migrar los sistemas a una base de datos documental, enfrentando la curva de aprendizaje y refactorización de código, solo para descubrir que en producción los tiempos de latencia se mantienen iguales.
Costo de Incurrir en Error Tipo II: No rechazar la H_0 cuando es falsa (Falso Negativo). Creeríamos erróneamente que ambos motores rinden igual, cuando MongoDB sí era más veloz. El impacto técnico es mantener una infraestructura relacional subóptima (PostgreSQL), experimentando cuellos de botella transaccionales y degradación de la experiencia del usuario que podrían haberse evitado.

Veredicto Formal: Dado que el p-value obtenido (5.46×10^{-9}) es estrictamente menor que

nuestro nivel de significancia ($\alpha=0.05$), existe evidencia estadística contundente para **Rechazar** la Hipótesis Nula H_0.

Recomendación de Ingeniería**:** Se comprueba que los tiempos de ejecución difieren significativamente entre ambas tecnologías. Al cruzar este veredicto con el Bloque 1 (donde MongoDB promedió 40.16 ms frente a los 48.53 ms de PostgreSQL), se recomienda la adopción de MongoDB para aquellos microservicios del proyecto que prioricen la velocidad bruta de lectura/escritura por encima del cumplimiento estricto de restricciones ACID relacionales.